

Técnica de Visualização Computacional Aplicada à Comparação de Variantes *LBP* para Extração de Características em Imagens Faciais

Caroline Mazini Rodrigues
Faculdade de Ciências e Tecnologia
Universidade Estadual Paulista - UNESP
Presidente Prudente, SP
Email: carolinemazinirodrigues@hotmail.com

Resumo—Uma imagem é formada por um conjunto de dados não-estruturados que podem, de alguma maneira, representar a natureza das formas que ela contém. Esses dados precisam ser estruturados para que possam ser representados e manipulados. Um tipo específico de imagens são as imagens faciais que podem ser utilizadas em diversas aplicações, incluindo o *Reconhecimento Facial*. O sucesso do processo de reconhecimento depende de inúmeros fatores, dentre eles, da qualidade das características extraídas, ou seja, da maneira como os dados são estruturados. O método *LBP* é baseado na descrição de texturas de imagens e é utilizado neste trabalho para a extração de características faciais. Para que seja possível comparar o desempenho das variantes *LBP* utilizadas, as características obtidas são projetadas, utilizando técnicas de redução de dimensionalidade (*PCA* e *MDS*), em um *Gráfico de Dispersão*.

I. INTRODUÇÃO

O reconhecimento de faces é algo facilmente realizado pelo ser humano. Desde a infância, esta habilidade possibilita a distinção entre pessoas familiares (cujas faces estão previamente armazenadas na memória do observador) e desconhecidas, auxiliando na socialização e convivência em grupos e, tornando o indivíduo capaz de associar sentimentos à pessoas, apenas por meio da visão de faces. Dado o grau de importância do reconhecimento na sociedade, sistemas são desenvolvidos baseando-se na capacidade humana de reconhecer faces através de imagens, buscando garantir segurança e confiabilidade à aplicações atuais.

Sistemas computacionais que realizam o *Reconhecimento Facial* (técnica biométrica) utilizam-se da *Visão Computacional* para capacitar um computador na tarefa de “ver” como um ser humano (ou o mais próximo de um ser humano quanto possível). Para isso, o computador faz uso de métodos matemáticos e estatísticos que possibilitam a extração de características úteis para a fase de comparação das faces.

Um dos métodos utilizados para a extração de características é o *Local Binary Pattern*, ou *LBP*. Este método consiste na obtenção de padrões binários locais que descrevam as texturas presentes na imagem. Assim que os padrões binários são obtidos, estes são utilizados para compor um histograma da imagem que servirá como característica para a comparação.

Durante a fase de comparação podem ser utilizados diferentes tipos de classificadores, dentre eles os classificadores não-supervisionados, que incluem o uso de métricas de distância entre os histogramas e, conseqüentemente, entre as faces correspondentes. No entanto, mesmo possuindo os valores de distanciamento entre as faces calculados, pode não ser tão simples interpretar e detectar agrupamentos de faces. Dessa maneira, partindo do princípio de que o ser humano processa com maior facilidade variáveis visuais, utilizou-se uma técnica de *Visualização Computacional* para representar as características extraídas de cada face.

Existem inúmeras técnicas de *Visualização Computacional* capazes de representar dados de maneira visual, a técnica utilizada neste trabalho é o *Gráfico de Dispersão*, ou *Scatterplot*. Nesta técnica, as características mais discriminantes de cada entidade que compõe o conjunto a ser analisado são projetadas como coordenadas x e y , gerando um gráfico. Este gráfico, por ser um ferramenta visual, auxilia na interpretação geral dessas distâncias entre faces de forma mais rápida e intuitiva.

O presente trabalho aborda na Seção ?? o método de extração de características *LBP* assim como algumas de suas variantes; na Seção ?? a técnica de *Visualização Computacional* utilizada para representação das faces, já com as características extraídas; na Seção ?? a descrição dos experimentos realizados e das bases de faces utilizadas; na Seção ?? os resultados encontrados a partir do sistema computacional implementado e; na Seção ?? as conclusões obtidas por meio da visualização das características faciais.

II. FUNDAMENTAÇÃO TEÓRICA

Um imagem é uma matriz de *pixels* e pode ser definida como um conjunto de dados não-estruturados. A estruturação dos dados contidos na imagem é necessária para que seja possível obter informações e assim, ser capaz de classificar, agrupar, separar e até mesmo, reconhecer. Para que seja possível realizar a estruturação, é necessário extrair características das imagens, partindo dos *pixels* presentes. O *Local Binary Pattern* foi o método utilizado neste trabalho para realizar essa extração.

O *LBP*, se originou como uma técnica de descrição de texturas proposta em [?], e foi posteriormente utilizada para *Reconhecimento Facial* em [?]. Este método apresenta simplicidade computacional e pouca variação sob mudanças de iluminação (escala de cinza) [?]. O conceito principal do *LBP* é o mapeamento binário das diferenças de nível de cinza, *Grey-Level Difference (GD)*, entre uma vizinhança e seu *pixel* central. Uma *GD*, no *LBP* original, é codificada em 0's e 1's de acordo com a Equação ??, onde f_p é um *pixel* da vizinhança e f_c é o *pixel* central. Cada um dos vizinhos contribui com seu valor binário para compôr um código *LBP* por meio da Equação ??.

$$S(f_p - f_c) = \begin{cases} 1, & f_p - f_c \geq 0 \\ 0, & f_p - f_c < 0 \end{cases} \quad (1)$$

$$LBP_{P,R} = \sum_{p=0}^{P-1} S(f_p - f_c) 2^p \quad (2)$$

Como é possível observar na Equação ??, o *LBP* é representado por $LBP_{P,R}$ onde P é a quantidade de vizinhos e R é o raio de abrangência da vizinhança. Através da Figura ?? é possível observar a execução do método *LBP* para $P = 8$ e $R = 1$. Apesar de originalmente contar com uma vizinhança quadrada, existem variações que possibilitam melhorias nos resultados, como a utilização da vizinhança circular, conforme exemplos representados pela Figura ??.




Figura 1. Exemplo de construção do código *LBP* em uma vizinhança com $P = 8$ e $R = 1$.

Fonte: Retirado de [?].




Figura 2. Exemplo de vizinhança circular.

Fonte: Retirado de [?].

$$x_p = x + R \cos\left(\frac{2\pi p}{P}\right) \quad (3)$$

$$y_p = y - R \sin\left(\frac{2\pi p}{P}\right) \quad (4)$$

Além da vizinhança circular, pode-se focar em regiões de maior interesse na face, atribuindo diferentes pesos à comparação de *pixels* de acordo com a importância que deseje-se dar para determinadas regiões durante o reconhecimento, como expresso em [?]. Essas regiões de maior interesse podem ser olhos, nariz, boca e sobrancelhas, por exemplo, conforme Figura ??.

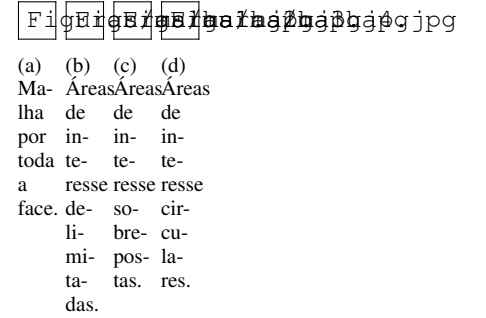


Figura 3. Exemplo de regiões de interesse utilizadas no *LBP*.

Fonte: Retirado de [?].

Antes da comparação *LBP*, a imagem pode ser dividida em n sub-janelas que manterão os padrões locais. Assim que o código *LBP* de cada um dos *pixels* de uma sub-janela é encontrado, pode-se determinar o histograma relativo à cada um dos códigos binários dentro da região. O histograma final é obtido a partir da concatenação dos histogramas menores (das sub-janelas) e apresenta dimensionalidade $256n$ em um *LBP* com vizinhança contendo 8 *pixels*, por exemplo.

Apesar da capacidade do método *LBP* em descrever texturas, alguns problemas clássicos do *Reconhecimento Facial* permanecer presentes, dentre eles problemas em reconhecer faces sob diferenças de postura, expressão, orientação, escala e, casos de oclusão, no entanto, é difícil encontrar uma técnica que possa solucionar todos esses problemas, assim, cada uma delas busca focar problemas específicos [?]. Algumas destas técnicas combinam mais de um método ainda mantendo a essência do *LBP* original e buscam trazer melhorias de desempenho.

A. Algumas Variantes *LBP*

Uma das variantes é o *Padrão Binário Local baseado no Gradiente*, ou *Gradient-Based Local Binary Pattern (GLBP)*, que utiliza como limiar (*threshold*), em uma vizinhança com $P = 8$, a diferença absoluta entre (p_0, p_4) e (p_2, p_6) de acordo com a Equação ??, onde p_c é o *pixel* central, p_j é o j -ésimo vizinho, P_+ é dado pela Equação ?? e $s(x)$ pela Equação ?? [?].

$$f_{GLBP}(x) = \sum_{j=0}^7 s(P_+ - |p_j - p_c|) 2^j \quad (5)$$

$$P_+ = \frac{1}{2} (|p_0 - p_4| + |p_2 - p_6|) \quad (6)$$

$$s(x) = \begin{cases} 1, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (7)$$

A vantagem do *GLBP* é que, como o limiar deixa de ser 0 e passa a ser o gradiente da vizinhança, os códigos *LBP* obtidos representarão os padrões mais discriminantes da face, destacando as regiões onde ocorre maior variação de textura, como os olhos, nariz e boca.

Outra variante é o *LBP Linear*, ou *Local Linear Binary Pattern (LLBP)*, proposta em [?], cuja ideia central é encontrar o código binário linear horizontal e vertical separadamente, assim como a magnitude, caracterizando as mudanças de intensidade da imagem. A diferença entre o *LBP* padrão e o *LLBP* consiste basicamente na forma da vizinhança e nos pesos atribuídos a cada *pixel* dela. A vizinhança é consituída por uma linha reta na vertical e outra na horizontal de tamanho N , já os pesos começam a serem atribuídos aos *pixels* diretamente adjacentes ao *pixel* central, recebendo 2^0 , até os *pixels* da extrema direita e esquerda, que recebem, no caso de uma vizinhança com $N = 9$ por exemplo: $2^{\lceil 9/2 \rceil - 2} = 2^3$. A aplicação de uma vizinhança com $N = 9$ juntamente com os pesos de cada *pixel* pode ser observada na Figura ?? . Pode-se também expressar pelas Equações ??, ?? e ?? a contrução do *LLBP* horizontal, ou *LLBP_h*, do *LLBP* vertical, ou *LLBP_v* e, *LLBP* da magnitude, ou *LLBP_m*, respectivamente, tendo c como a posição do *pixel* central. A Figura ?? mostra a face original e a face depois da aplicação do *LLBP* horizontal, vertical e magnitude.




Figura 4. Exemplo de aplicação de vizinhança linear $N = 9$ e pesos dos *pixels*.

Fonte: Retirado de [?].

$$LLBP_h = \sum_{n=1}^{c-1} s(h_n - h_c) 2^{(c-n-1)} + \sum_{n=c+1}^N s(h_n - h_c) 2^{(n-c-1)} \quad (8)$$

$$LLBP_v = \sum_{n=1}^{c-1} s(v_n - v_c) 2^{(c-n-1)} + \sum_{n=c+1}^N s(v_n - v_c) 2^{(n-c-1)} \quad (9)$$

$$LLBP_m = \sqrt{LLBP_h^2 + LLBP_v^2} \quad (10)$$

III. TÉCNICA DE VISUALIZAÇÃO

A partir da estruturação dos dados das imagens faciais torna-se possível a aplicação de técnicas de *Visualização Computacional*. Estas técnicas servem como um meio de analisar as similaridades e agrupamentos que possam determinar faces da mesma pessoa, assim como podem explicitar *outliers*, faces que não se enquadrem na classe correspondente, e auxiliar na verificação da causa dessa ocorrência. A facilidade na absorção do conhecimento a partir de variáveis visuais simplifica a




Figura 5. Face na qual foi aplicada o operador *LLBP* com vizinhança de 9 *pixels*.

Fonte: Retirado de [?].

compreensão do desempenho de cada variante *LBP* utilizada na extração de características.

A técnica de visualização utilizada com o intuito de representar as características extraídas foi o *Gráfico de Dispersão (Scatterplot)*, através de função já implementada do *Matlab*, que busca mapear os atributos de cada entidade (face) representada em variáveis de posicionamento (coordenadas) no plano cartesiano.

O *Gráfico de Dispersão*, tanto 2D quanto 3D, é uma das técnicas mais utilizadas na *Visualização Computacional* [?]. Isto porque, o ser humano possui grande capacidade de percepção de distâncias e posicionamento em um espaço delimitado [?]. O uso desta técnica no contexto atual, proporciona facilidade na observação de proximidade entre faces.

A. Redução de Dimensionalidade

Como as características extraídas excedem o número de coordenadas a serem mapeadas, é necessário o uso de uma técnica de redução de dimensionalidade. Partindo do conjunto composto pelos histogramas concatenados obtidos após a execução das técnicas *LBP*, é preciso transformar os dados de forma que eles mantenham suas características principais em menor dimensão de atributos. Para isso, foram utilizados os métodos *Análise do Componente Principal*, *Principal Component Analysis (PCA)* e, *Multidimensional Scaling (MDS)*.

1) **PCA**: É capaz de reduzir a dimensionalidade utilizando uma transformação linear onde o primeiro elemento principal é a combinação das dimensões de maior variância e o n -ésimo é a combinação linear de maior variância ortogonal a todos os componentes principais anteriores [?]. O objetivo principal é definir as direções que melhor representam as características do conjunto de dados, conforme a Figura ??.




Figura 6. Exemplo de vetores que melhor representam as características.

Fonte: Retirado de [?].

O processo de execução do método consiste em:

- Encontrar a média de cada conjunto de características;

- Subtrair a média correspondente de cada característica;
- Encontrar a matriz de covariância, pela Equação ??, onde i, j é o elemento na linha i e coluna j e $\mu_i = E(X_i)$ e $E(X)$ é o valor esperado;

$$x(i, j) = E[(X_i - \mu_i)(X_j - \mu_j)] \quad (11)$$

- Obter os *autovalores* (λ) e *autovetores* (v) a partir da matriz de covariância, através da Equação ??;

$$T(v) = \lambda v \quad (12)$$

- Ordenar os *autovetores* de forma decrescente em relação aos *autovalores* correspondentes e assim utilizar os *autovetores* que melhor classificam a face, ou seja, de maiores *autovalores*.

Os *autovetores* mantidos são colocados em uma matriz e utilizados na composição do conjunto final de dados, expressa na Equação ??, onde $M_{caracteristicas}$ é a matriz de *autovetores* escolhidos e M_{dados} é a matriz de dados iniciais.

$$V_{final} = M_{caracteristicas} \cdot M_{dados} \quad (13)$$

2) **MDS**: Trata-se de uma classe de algoritmos para projeção multidimensional. Uma de suas implementações mais simples foi proposta em [?], contando com o seguinte processo:

- Obter matriz de similaridade entre os pares de atributos da matriz de dados a serem projetados (pode-se utilizar distância euclidiana como métrica de similaridade);
- Definir uma matriz contento as coordenadas aproximadas (ou aleatórias) de cada uma das instâncias na projeção;
- Obter matriz de similaridade da matriz de coordenadas para projeção;
- Obter a diferença entre as matrizes de similaridade dos dados reais e dos dados projetados, esta diferença é chamada *stress*;
- Caso o valor do *stress* não sofra modificações significativas ao longo das últimas iterações do processo ou seja suficientemente pequeno, o resultado passa a ser composto pelas coordenadas obtidas na matriz de projeção;
- Caso contrário, as coordenadas das instâncias projetadas são movidas seguindo a direção de diminuição do *stress* e este é recalculado para uma próxima iteração.

O algoritmo utilizado durante a implementação deste trabalho é uma função do *Matlab*.

B. Variáveis Visuais e Interação

Além das coordenadas x e y que mapeam o posicionamento das faces, outras variáveis são utilizadas no *Gráfico de Dispersão* desenvolvido para este trabalho, proporcionando melhor representação do conjunto de imagens, além de auxiliar na interação do usuário com o conjunto de dados.

A primeira dessas variáveis é a *cor*, utilizada como forma de separação de classes, já que as imagens utilizadas são previamente nomeadas de acordo com a pessoa à qual a face

pertence, assim, é possível observar a formação de grupos de acordo com a técnica de extração de características utilizada.

A segunda variável é a forma, que é modificada de acordo com a seleção ou não seleção de uma classe de imagens. Assim que uma face é selecionada, ela e todas as demais faces pertencentes à mesma classe possuem a forma alterada para obter destaque em relação às demais, facilitando a análise de grupos. Além disso, assim que uma classe é selecionada, todas as suas entidades são conectadas por linhas pontilhadas, destacando o caminho que minimiza a distância entre os pares de entidades entidades.

Quando a seleção está ativa, um ambiente de navegação é habilitado e, caso qualquer uma das entidades do conjunto de dados seja selecionada, um rótulo com o identificador da imagem é exibido, podendo ser escondido com um clique do botão esquerdo. As teclas ENTER e ESC encerram o ambiente de navegação e todas as imagens cujos rótulos estão sendo exibidos são mostradas em tela. Quando a seleção de uma segunda classe é realizada com o ambiente de navegação já encerrado, a primeira classe até então selecionada volta à forma original, perdendo o destaque.

IV. EXPERIMENTOS

Durante a fase de experimentação, definiu-se alguns parâmetros de teste nas categorias: variante *LBP* para extração de características e tamanho de sub-janela de cada histograma produzido para as imagens. As variantes *LBP* utilizadas foram:

- *LBP* padrão
- *LBP* circular
- *LBP* circular gradiente
- *LBP* linear

O tamanho de sub-janela utilizado na construção do histograma define as regiões que manterão seus padrões locais. Quanto menor o tamanho da sub-janela, maior a dimensionalidade do histograma final formado pela concatenação dos histogramas locais. Os tamanhos utilizados foram:

- 500x500 *pixels*
- 50x50 *pixels*

A. Bases de Dados Faciais

Os experimentos ocorreram utilizando duas bases de dados faciais: a *IMM Face Database* e a *Japanese Female Facial Expression (JAFFE)*. As bases contém as seguintes especificações:

IMM: contém 240 imagens *RGB* anotadas (foram utilizadas as originais) de 40 pessoas (33 homens e 7 mulheres, com 6 imagens de cada um) sem óculos obtidas em janeiro de 2001, contando com diferenças de expressão, posicionamento e iluminação [?], [?].

JAFFE contém 213 imagens faciais frontais em escala de cinza de 10 mulheres japonesas com 7 diferentes expressões faciais (6 expressões básicas e 1 neutra) [?].

V. RESULTADOS

Por meio dos experimentos realizados utilizando as duas bases de dados descritas, os seguintes resultados foram obtidos para cada técnica:

O **LBP padrão** representa a técnica original e mais básica do *LBP*, os resultados obtidos para a projeção da base *IMM* apresentam pequenos agrupamentos de entidades de cada classe, no entanto, classes diferentes se encontram muito próximas, principalmente com o uso do método *PCA* (Figura ??). A projeção que utiliza o método *MDS* (Figura ??) possibilita maior espalhamento das classes possibilitando melhor visualização das relações, assim como, o uso de sub-janelas menores (Figuras ??(b) e ??(b)) proporciona melhorias para a extração de características e, conseqüentemente, para a projeção.




Figura 7. Visualização da base de imagens faciais *IMM* após extração de características por meio do *LBP* padrão e projeção utilizando *PCA*.
Fonte: Autoria própria.




Figura 8. Visualização da base de imagens faciais *IMM* após extração de características por meio do *LBP* padrão e projeção utilizando *MDS*.
Fonte: Autoria própria.

O *LBP* padrão apresenta resultados similares para a base *JAFFE*. As projeções que utilizando o método *MDS* (Figura ??) proporcionam maior espalhamento entre-classes do que as projeções com o método *PCA* (Figura ??). Além disso, a extração de características feita com sub-janelas menores (Figuras ??(b) e ??(b)) realizam aproximação intra-classes.




Figura 9. Visualização da base de imagens faciais *JAFFE* após extração de características por meio do *LBP* padrão e projeção utilizando *PCA*.
Fonte: Autoria própria.




Figura 10. Visualização da base de imagens faciais *JAFFE* após extração de características por meio do *LBP* padrão e projeção utilizando *MDS*.
Fonte: Autoria própria.

O **LBP circular** apresenta resultados mais estáveis com relação à base *IMM*. As visualizações cujos dados são extraídos a partir de sub-janelas menores (Figuras ??(b) e ??(b))

continuam apresentando maior espalhamento entre-classes do que regiões com maiores sub-janelas (Figuras ??(a) e ??(a)), possuindo, no entanto, uma variação menos pronunciada.




Figura 11. Visualização da base de imagens faciais *IMM* após extração de características por meio do *LBP* circular e projeção utilizando *PCA*.
Fonte: Autoria própria.




Figura 12. Visualização da base de imagens faciais *IMM* após extração de características por meio do *LBP* circular e projeção utilizando *MDS*.
Fonte: Autoria própria.

Para a base *JAFFE*, pode-se observar que ocorre otimização nos agrupamentos de classe quando utiliza-se o *LBP* circular ao invés do *LBP* padrão. Além disso, o método de projeção *MDS* (Figura ??) apresenta melhores resultados que o método *PCA* (Figura ??) com relação ao agrupamento intra-classes. As sub-janelas menores continuam apresentando resultados melhores para o distanciamento de classes diferentes.




Figura 13. Visualização da base de imagens faciais *JAFFE* após extração de características por meio do *LBP* circular e projeção utilizando *PCA*.
Fonte: Autoria própria.




Figura 14. Visualização da base de imagens faciais *JAFFE* após extração de características por meio do *LBP* circular e projeção utilizando *MDS*.
Fonte: Autoria própria.

O método do **LBP circular gradiente**, como esperado, apresenta desempenho semelhante ao *LBP* circular, já que conta com o mesmo princípio de extração, no entanto, como no *LBP* circular gradiente procura-se ressaltar características mais discriminantes de cada face, este proporciona melhoria quanto ao distanciamento entre-classes. Dessa maneira, utilizando a base de dados *IMM* (Figuras ?? e ??) as estruturas formadas nas visualizações não se modificam drasticamente com relação ao circular, apenas inclui maior distância entre os grupos formados.

Da mesma maneira, ao utilizar a base *JAFFE* (Figuras ?? e ??), os grupos formados pelo *LBP* circular permanecem, mas tornam-se mais definidos.




Figura 15. Visualização da base de imagens faciais *IMM* após extração de características por meio do *LBP* circular gradiente e projeção utilizando *PCA*.
Fonte: Autoria própria.




Figura 16. Visualização da base de imagens faciais *IMM* após extração de características por meio do *LBP* circular gradiente e projeção utilizando *MDS*.
Fonte: Autoria própria.

No ***LBP linear*** os agrupamentos não são tão bem definidos quanto nos demais métodos. Nota-se que na base *IMM* (Figuras ?? e ??) a diferença entre os tamanhos das sub-janelas gera mudança significativa na visualização, principalmente quando utilizado o método *PCA* (Figura ??).

Aplicado à base *JAFPE*, o *LBP linear* utilizando o método *PCA* (Figura ??) também não apresenta desempenho satisfatório, no entanto, quando aplicado juntamente com o método *MDS* (Figura ??) proporciona agrupamentos mais pronunciados.

VI. CONCLUSÕES

Com base nos resultados obtidos através dos experimentos pode-se notar que os métodos *LBP* utilizados tornam-se eficazes quando as faces envolvidas não sofrem grandes variações de posicionamento, sofrendo um impacto menor quanto à variações de iluminação. Exemplos disso foram os experimentos utilizando a base *IMM* que apresentaram agrupamento parcial de instâncias de cada classe, em razão da natureza das imagens (diferentes orientações das faces); por outro lado, os experimentos com a base *JAFPE* mostraram agrupamentos definidos com maior precisão, já que esta base é constituída por imagens faciais frontais.

Além disso, nota-se também que, em todos os experimentos, as visualizações que contam com as características extraídas através de sub-janelas menores apresentam maior espalhamento entre os agrupamentos formados e, caso estes agrupamentos sejam bem definidos pela metodologia de extração de características, ocorre uma ampliação do distanciamento entre-classes.

Outra observação importante é que, o método *LBP* circular gradiente produziu resultados melhores que os demais métodos experimentados durante a formação de grupos da mesma classe.

Por fim, deve-se destacar que, a técnica de redução de dimensionalidade *MDS* apresentou resultados mais satisfatórios que a técnica *PCA*, tornando a visualização mais clara e possibilitando com maior facilidade a observação das informações anteriormente apresentadas.




Figura 17. Visualização da base de imagens faciais *JAFPE* após extração de características por meio do *LBP* circular gradiente e projeção utilizando *PCA*.
Fonte: Autoria própria.




Figura 18. Visualização da base de imagens faciais *JAFPE* após extração de características por meio do *LBP* circular gradiente e projeção utilizando *MDS*.
Fonte: Autoria própria.




Figura 19. Visualização da base de imagens faciais *IMM* após extração de características por meio do *LBP linear* e projeção utilizando *PCA*.
Fonte: Autoria própria.




Figura 20. Visualização da base de imagens faciais *IMM* após extração de características por meio do *LBP linear* e projeção utilizando *MDS*.
Fonte: Autoria própria.




Figura 21. Visualização da base de imagens faciais *JAFPE* após extração de características por meio do *LBP linear* e projeção utilizando *PCA*.
Fonte: Autoria própria.

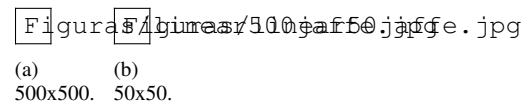


Figura 22. Visualização da base de imagens faciais *JAFPE* após extração de características por meio do *LBP linear* e projeção utilizando *MDS*.
Fonte: Autoria própria.